

Ежедневный Тренинг

Flops

$$X \in \mathbb{R}^{B \times 3 \times S \times S}, \quad S = 16n, \quad n \in \mathbb{N}$$

FP32 $\Rightarrow$ 1 элемент — это 4 байта

1 multiply-accumulate = 2 FLOPs

Размерность при свертке + выводе:

$$S_{out} = \left\lfloor \frac{S_{in} + 2padding - kernel_size}{stride} \right\rfloor + 1$$


Поскольку 1) $S \bmod 16 = 0$
2) $padding = kernel_size // 2 \geq mo$
3) $kernel_size$ нечетный.

$$S_{out} = \left\lfloor \frac{S_{in} - 1}{stride} \right\rfloor + 1$$

Если

- $stride = 1$: $\lfloor S_{in} - 1 \rfloor + 1 = S_{in} - 1 + 1 = S_{in}$
- $stride = 2$: $\left\lfloor \frac{S_{in}}{2} - \frac{1}{2} \right\rfloor + 1 = \frac{S_{in}}{2} - 1 + 1 = \frac{S_{in}}{2}$

Итого из этого получим размерности



o) (B, 3, S, S) - bag

Action	Output Shape
Conv 7x7 S2 p3 3→32	(B, 32, S/2, S/2)
ReLU	1-11-1
Max Pool 3x3 S2 p1	(B, 32, S/4, S/4)
Conv 5x5 S1 p2 32→64	(B, 64, S/4, S/4)
ReLU	1-11-1
Conv 3x3 S2 p1 64→128	(B, 128, S/8, S/8)
ReLU	1-11-1
Conv 1x1 S1 p0 128→256	(B, 256, S/8, S/8)
ReLU	1-11-1
Conv 3x3 S2 p1 256→256	(B, 256, S/16, S/16)
ReLU	1-11-1
Conv 1x1 S1 p0 256→512	(B, 512, S/16, S/16)
ReLU	1-11-1
Global Avg Pool	(B, 512, 1, 1)
Flatten	(B, 512)
Linear 512→256	(B, 256)
Linear 256→100	(B, 100)

Выходной элемент свертки:

$$\text{out}[C, i, j] = \sum_{C'=0}^{C_{in}-1} \sum_{u=0}^{K-1} \sum_{v=0}^{K-1} W[C, C', u, v] \cdot x[C', i \cdot S + u - p, j \cdot S + v - p]$$

$C_{in} K^2$ умножений на 1 элемент

$$FLOP_s = 2 \cdot C_{in} K^2 \text{ — на 1 элемент}$$

Выходные элементы: $C_{out} \cdot S^2$

Тогда

$$FLOP_s = 2 C_{out} S^2 C_{in} K^2$$

C Размером канала B:

$$FLOP_s = 2 B C_{out} C_{in} S^2 K^2$$

1) Conv 1 $F_1 = 2B \cdot 3 \cdot 32 \cdot \left(\frac{S}{2}\right)^2 \cdot 7^2 = 2352 BS^2$

2) Conv 2 $F_2 = \frac{2B \cdot 64 \cdot 32 \cdot S^2 \cdot 5^2}{4^2} = 6400 BS^2$

3) Conv 3 $F_3 = 2B \cdot 128 \cdot \left(\frac{S}{8}\right)^2 \cdot 64 \cdot 3^2 = 2304 BS^2$

4) Conv 4 $F_4 = 2B \cdot 256 \cdot 128 \cdot \left(\frac{S}{8}\right)^2 \cdot 1^2 = 1024 BS^2$

5) Conv 5 $F_5 = 2B \cdot 256^2 \cdot \left(\frac{S}{16}\right)^2 \cdot 8^2 = 4608 BS^2$

6) Conv 6 $F_6 = 2B \cdot 512 \cdot 256 \cdot \left(\frac{S}{16}\right)^2 \cdot 1^2 = 1024 BS^2$

$$F_{conv} = 17712 BS^2$$

Для матрицы

$$W \times b$$

$$FLOPs = 2B C_n C_{out}$$

1) Linear 1 : $F_{fc1} = 2B \cdot 512 \cdot 256 = 262144 B$

2) Linear 2 $F_{fc2} = 2B \cdot 256 \cdot 100 = 51200 B$

Конкретно можно увидеть нет в ReLU,
пусть так это даже движение в
сторону нейронизации

Итого $FLOPs(S, B) = 17712 BS^2 + 313344B$

Посчитаем кол-во параметров:

Conv 1	$32 \cdot 7^2 \cdot 3 = 4704$	Conv 4	$256 \cdot 128 = 32768$
Conv 2	$64 \cdot 32 \cdot 5^2 = 51200$	Conv 5	$256 \cdot 256 \cdot 3^2 = 589824$
Conv 3	$128 \cdot 64 \cdot 3^2 = 73728$	Conv 6	$512 \cdot 256 = 131072$

Linear 1 $512 \cdot 256 + 256 = 131328$

Linear 2 $256 \cdot 100 + 100 = 25700$

$$P = 1040324 \text{ элементов}$$

$$4P = 4161296 \text{ bytes}$$

Memory

input

Conv1

Maxpool

Conv2

Conv3

Conv4

Conv5

Conv6

$$3BS^2$$

$$3BS^2 + 3BS^2$$

$$8BS^2 + 2BS^2$$

$$2BS^2 + 4BS^2$$

$$4BS^2 + 2BS^2$$

$$2BS^2 + 4BS^2$$

$$4BS^2 + BS^2$$

$$BS^2 + 2BS^2$$

$$3BS^2$$

$$11BS^2$$

$$10BS^2$$

$$6BS^2$$

$$6BS^2$$

$$6BS^2$$

$$5BS^2$$

$$3BS^2$$

$$\text{Max} = 11BS^2 \quad \text{FP32 Elements}$$

Тогда, зная, что процессоры могут
работать на GPU

$$\text{Memory}(S, B) = 4(1040324 + 11BS^2) \text{ байт}$$

Bytes moved

Принимаю такие данные:

- 1) Промежуток X
- 2) Промежуток W
- 3) Занесем Y

$$\text{Тогда } \text{Bytes}_{\text{conv}} = (N_x + N_w + N_y) \cdot 4 \quad \leftarrow \text{по 4 байта FP32}$$

Для ReLU — реализуется inplace=True =>

$$\Rightarrow \text{Bytes}_{\text{ReLU}} = 4(N_x + N_y) = 8N_x \quad (\text{box} = \text{box}_y)$$

Дан гипер: $\text{Hago prurum amь + Zanneame, BecoBnem}$
Bytes pool = $4(N_x + N_y)$

Умноо:

conv 1	$11BS^2 + 4704$
ReLU 1	$16BS^2$
Max pool	$10BS^2$
conv 2	$6BS^2 + 51200$
ReLU 2	$8BS^2$
conv 3	$6BS^2 + 73728$
ReLU 3	$4BS^2$
conv 4	$6BS^2 + 32768$
ReLU 4	$8BS^2$
conv 5	$5BS^2 + 589824$
ReLU 5	$2BS^2$
conv 6	$3BS^2 + 131072$
ReLU 6	$4BS^2$
GAP	$2BS^2 + 512B$
Linear 1	$768B + 181328$
ReLU 7	$512B$
Linear 2	$356B + 25700$

$$\text{Bytes Moved} = 4(91BS^2 + 2148B + 1040324)$$

Latency

Для каждого ядра GPU

$$T_{\text{layer}} = \max \left(t_{\text{launch}}, \frac{\text{Bytes}_e}{\text{BW}}, \frac{\text{FLOPs}}{P} \right)$$

BW - скорость памяти

P - эффективная вычислительная пропускная способность

Тогда сумма по всем слоям, то есть

$$\text{Latency}(S, B, \Theta) = \sum_e \max \left(t_{\text{launch}}, \frac{\text{Bytes}_e}{\text{BW}}, \frac{\text{FLOPs}}{P} \right)$$

3 режима comb. → launch-bound
memory-bound
compute-bound

Energy

$$\text{Energy}(S, B, \Theta) = P_0 \cdot \text{Latency}(S, B, \Theta) + \epsilon_H \cdot \text{Bytes Moved}(S, B) + \epsilon_F \cdot \text{FLOPs}(S, B)$$

↑
эффективная энергия
на Byte traffic

↑
эффективная энергия
на FLOP